

INFO PERSONALI

Somma Lombardo (VA)
fed.dimaio@gmail.com
+39 320 228 6941
04/04/1990, Gallarate
Nazionalità: Italiana

COMPETENZE DIGITALI

2FA AD Angular
Apache Directory Studio
ArgoCD AWS BERT
DBeaver Docker Eclipse
Elastic Fiddler
Fine-tuning LLM Git
Google Gemini
Hugging Face
IntelliJ IDEA Java
JavaScript Jupyter
Kubernetes LDAP
MobaXterm MongoDB
Neo4j Ollama
OpenAI API Openshift
Pandas PostgreSQL
Postman Protegè
PyCharm Python PyTorch
REST Scikit-learn
Scipy SourceTree Spacy
Spring Boot SQL
Studio3T TensorFlow
Transformers VSCode
Vue.js Weaviate

LINK

LinkedIn
ResearchGate
GitHub

SOFT SKILLS

Creativity, Leadership,
Flexibility, Team Work,
Problem Solving

LINGUE

Italiano
Inglese B1

Federico Di Maio

DATA SCIENTIST | AI ENGINEER

Somma Lombardo (VA) • fed.dimaio@gmail.com • +39 320 228 6941

PROFILO PROFESSIONALE

AI Engineer e Data Scientist con esperienza nell'implementazione di servizi di intelligenza artificiale e nello sviluppo back-end, specializzato nello sviluppo di chatbot basati su RAG (Retrieval-Augmented Generation), servizi agent-based e fine-tuning di modelli linguistici. Competenze consolidate nello sviluppo in Java e Python.

ISTRUZIONE E FORMAZIONE

Laurea in Ingegneria Informatica, Università Guglielmo Marconi, Roma Gen 2020 – Lug 2024
Perito in elettronica e telecomunicazioni, IIS Carlo Alberto Dalla Chiesa, Sesto Calende Set 2004 – Giu 2009

ESPERIENZA LAVORATIVA

Data Scientist — Leithà Ott 2025 – oggi

Data Science Lead Fine-tuning

Data Scientist e AI Engineer con focus su progetti di intelligenza artificiale e sviluppo di soluzioni innovative per il settore assicurativo.

- FedMan:** progetto di fine-tuning con la libreria Unsloth e componente custom di valutazione F1-score. Modelli fine-tuned: unsloth/Qwen3.6-35B-A3B, unsloth/Qwen3.6-27B, Qwen3.5-35B-A3B — miglioramento delle performance del +10% rispetto al modello base.
- Rivalse:** servizio GenAI per il supporto alla gestione dei sinistri e delle rivalse assicurative. Implementato un classificatore basato su XLM-RoBERTa per la classificazione di pagine documentali, con precisione del 97% e un risparmio sui costi API verso Gemini di circa 500€/giorno; modello fine-tuned tramite unfreezing (full fine-tuning).
- Lei-Exodia:** libreria Python per l'estrazione intelligente di informazioni da polizze assicurative, tramite un modello di linguaggio vision (Qwen via vLLM, con Gemini come fallback) orchestrato tramite pipeline agentica per estrazioni precise e validate.
- Eddie:** servizio GenAI di conversione da linguaggio naturale a query SQL (NLP-to-SQL), con supporto multi-dialetto (SQLite, PostgreSQL, ecc.), ispezione automatica dello schema del database con caching per ridurre i tempi di risposta, visualizzazione e query tramite Datasette, deployment containerizzato con Docker Compose e integrazione con Google Cloud Platform / Vertex AI.
- Leitac:** sistema di rilevamento delle manomissioni in immagini mediche DICOM, basato sulla ricerca "Forensic detection of medical image manipulation using PACS and DICOM artifacts" (Oh et al., Journal of Forensic Sciences, 2025); analizza i metadati DICOM per identificare modifiche non autorizzate ai file di imaging medico.

AI Specialist — Cineca, Milano

Lug 2023 – Ott 2025

- **Lumia:** servizio multi-agente per il monitoraggio, aggiornamento e supporto operativo di 8 chatbot destinati ai consorziati del Cineca.
- **Sonia University:** assistente virtuale per la piattaforma University, a supporto della ricerca e consultazione di metadati sui corsi di studio.
- **Anvur_VQR:** sistema RAG per l'analisi e valutazione di abstract scientifici, a supporto dei revisori nel processo di revisione accademica.
- **Unifind:** chatbot per l'Università di Torino con agente AI in grado di interrogare un database a grafo Neo4j, generando query Cypher da input in linguaggio naturale.
- **HR-suite:** chatbot per l'accesso alla documentazione interna del Cineca tramite web/document scraping per indicizzare e interrogare i materiali interni.

AI Specialist - Freelance — Monrif, Bologna

Gen 2025 – Dic 2025

Progettazione e sviluppo di un sistema di gestione documentale con Weaviate per l'archiviazione e l'analisi semantica di articoli giornalistici e immagini, con similarity search per l'identificazione automatica di contenuti correlati e l'ottimizzazione dei tempi di ricerca.

AI Researcher - Freelance — Isagog, Rome

Ott 2023 – Ott 2024

RAG "Il Manifesto": studio di ricerca per implementare un assistente virtuale open source per la ricerca di articoli per il giornale "Il Manifesto".

Software Engineer — Cineca, Milano

Ott 2022 – Lug 2023

- **Team Identity:** sviluppo e risoluzione dei bug in produzione segnalati tramite ticket, garantendo l'affidabilità del sistema e il miglioramento continuo dei servizi offerti.
- **Università 2030:** WebApp rilasciata a luglio 2023, sviluppata in Java e Angular come supporto agli studenti e ai professori degli atenei del consorzio.

Tecnico Elettroavionico Aeronautico — Leonardo S.p.A, Vergiate

Lug 2011 – Ott 2022

Lavoratore esperto nella produzione aeronautica.

PUBBLICAZIONI (50+ citazioni)

Comparative Analysis of Prompt Strategies for LLMs: Single-Task vs. Multitasking Prompts

Ott 2024

Autori: Manuel Gozzi, Di Maio Federico • Editor: MDPI Applied Science

Lo studio analizza l'efficacia di diverse strategie di prompt engineering per Large Language Models, confrontando prompt single-task e multitasking, valutando se un unico prompt in grado di gestire più task contemporaneamente (NER, sentiment analysis, formattazione JSON) possa raggiungere prestazioni comparabili a prompt dedicati. I risultati, validati tramite test statistici (Wilcoxon, McNemar, Friedman) su cinque LLM open-weight (LLama3.1 8B, Qwen2 7B, Mistral 7B, Phi3 Medium, Gemma2 9B), mostrano che non esiste una regola univoca a favore dei prompt single-task: le prestazioni dipendono fortemente dai dati e dall'architettura del modello.

Degradation of Multi-Task Prompting Across Six NLP Tasks and LLM Families

Nov 2025

Autori: Di Maio Federico, Manuel Gozzi • Editor: MDPI Applied Science

Lo studio analizza come l'aumento della complessità dei prompt influisca sulle prestazioni degli LLM su più task di NLP, tramite un framework di valutazione incrementale che combina progressivamente sei task (formattazione JSON, traduzione inglese-italiano, sentiment analysis, classificazione delle emozioni, topic extraction e NER). La valutazione, su sei modelli open-source di famiglie diverse (Llama 3.1 8B, Gemma 3 4B, Mistral 7B, Qwen3 4B, Granite 3.1 3B, DeepSeek R1 7B), mostra che il degrado dipende fortemente dall'architettura: Qwen3 4B resta stabile su tutti i task, mentre Gemma 3 4B e Granite 3.1 3B collassano nei task semantici più fini. Alcuni modelli (Llama 3.1 8B, DeepSeek R1 7B) mostrano invece effetti di transfer positivo, suggerendo che la resilienza al multitask prompting dipende più dal design architetturale che dalla dimensione del modello.

CORSI

- Building RAG Agents with LLMs, NVIDIA — Luglio 2025
- Introduction to Transformer-Based Natural Language Processing, NVIDIA — Luglio 2025
- Generative AI Engineering and Fine-Tuning Transformers, IBM — Febbraio 2026